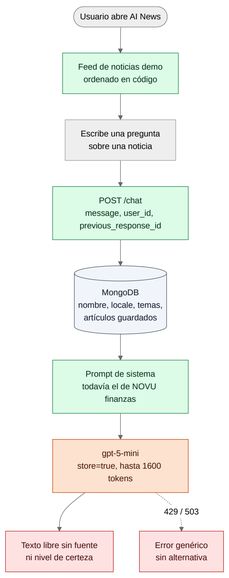
Rediseño del Proyecto 2 con Jev

AI News (ai-assisted-news-app) · flujo elegido: consulta sobre una noticia

Gustavo Cruz 22779 · Mathew Cordero 22982
Responsible AI · Design Thinking · Lean Thinking

LLM generación de texto · JEV decisión tipada · CODE lógica determinista

1. Flujo actual



Observado en el repositorio

- Cada pregunta llega a gpt-5-mini, aunque sea una fecha o una fuente.
- Se envían nombre, locale y temas del usuario con cada turno.
- store=true: el historial queda en OpenAI.
- El prompt sigue siendo el de NOVU finanzas.
- La app móvil aún no tiene pantalla de chat; el feed usa datos demo.

2. Usuario y necesidad

Persona Supuesto

Estudiante o profesional joven en Guatemala. Lee noticias en el celular entre clases o en el bus, con datos móviles limitados.

Necesidad

Entender rápido una noticia y saber si lo que lee está en la fuente o lo inventó la IA.

Punto del flujo a mejorar

El momento después de escribir la pregunta: hoy espera varios segundos un texto sin cita y sin señal de duda.

Qué cambia en la experiencia

- Sugerencias tocables para lo frecuente: fecha, fuente, resumen.
- Los datos puntuales llegan como cita del párrafo, resaltada en la noticia.
- La IA generativa queda para explicar contexto y se etiqueta como tal.
- Cuando el sistema duda, lo dice y ofrece una salida.

Cómo se mantiene el valor

La persona sigue obteniendo respuesta en lenguaje natural y gana trazabilidad: puede ver de qué párrafo sale cada dato.

3. Investigación: qué es Jev y qué implica usarlo

Tareas y límites frente a un LLM

Jev 1.13 recibe un estado en texto y preguntas tipadas. Devuelve respuestas con probabilidad y confianza en una sola llamada.

- Choice: elegir una opción de una lista.
- Score: calificar contra niveles de una rúbrica.
- Noul: probabilidad de que una afirmación sea verdadera.

Sirve para clasificar, enrutar, filtrar pasajes, verificar citas y extraer seleccionando entre candidatos.

Límites documentados por TypeSafe:

- No genera texto ni conversa.
- Falla en conteo, aritmética y comparación de fechas.
- Lee las instrucciones de forma literal.
- Pierde precisión con estados grandes o con contenido adversarial.
- Sólo texto; 64k tokens por solicitud.
- Entrenado sobre todo en inglés; en español la precisión es menor.

Datos enviados y políticas

Enviaríamos la pregunta sin datos personales y párrafos de la noticia, que es contenido público. No enviaríamos user_id, nombre, correo ni preferencias.

- Entrenamiento: la política de privacidad dice que no entrenan ni ajustan modelos con el input. Verificado
- Conservación: mientras sea razonablemente necesario; sin plazo fijo. Retención cero sólo para empresas. Verificado
- Ubicación: servicio alojado en EE. UU. Verificado
- Terceros: comparten input sólo con proveedores de servicio; lista de subencargados en el DPA. Verificado
- Telemetría: el sitio usa cookies y Google Analytics y registra IP, dispositivo y horarios. No encontramos qué registra la API por solicitud. Supuesto
- Acceso temprano por lista de espera; límites de uso cambian sin aviso. Verificado

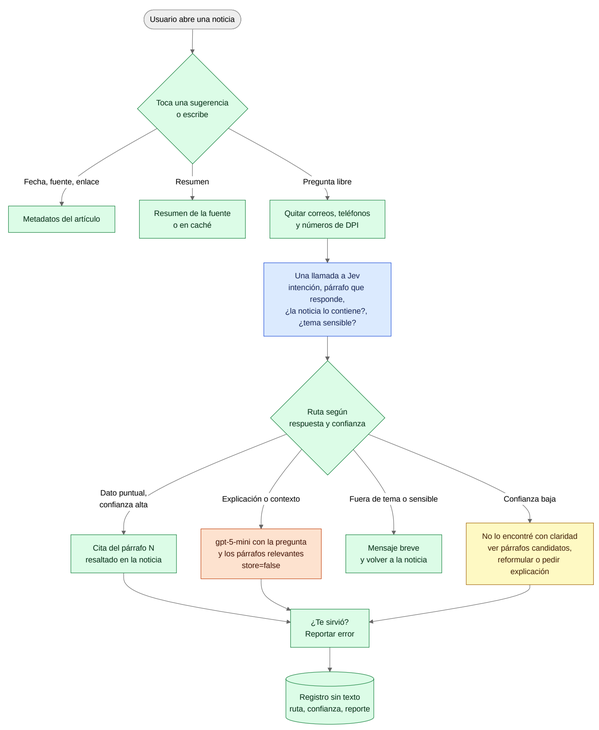
Velocidad, costo y recursos

- Jev: US$0.042 por millón de tokens de entrada; la salida no se cobra. Verificado
- gpt-5-mini: US$0.25 entrada y US$2.00 salida por millón. Verificado
- Límite Jev: 100k tokens/s y 40 solicitudes/s. Verificado
- 193.6x más rápido y 444.6x más barato que un LLM; 0.114 s frente a 8.566 s. Prueba interna sin método publicado. Proveedor
- 13 preguntas en una llamada: 0.27 s y US$0.0005, frente a 2.71 s con 13 llamadas. Proveedor
- Cero alucinaciones: válido sólo porque elige entre opciones dadas; puede elegir mal. Proveedor
- Energía o hardware por solicitud: no publicado. Supuesto
- Nuestros tiempos y costos por turno son estimaciones (ver panel 6). Supuesto

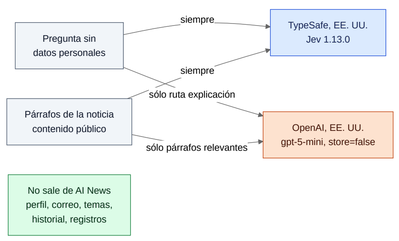
4. Matriz por función del flujo

Función	Elección	Justificación	UX	Privacidad	Velocidad	Costo y recursos	Funcionalidad
Mostrar fecha, fuente y enlace	CODE	Son metadatos del artículo; ningún modelo agrega valor.	Respuesta inmediata y exacta.	No sale nada.	Instantáneo.	Nulo.	Igual.
Mostrar resumen	CODE	La fuente ya trae summary; si falta, se genera una vez y se guarda.	Disponible al tocar, sin espera.	No sale nada.	Instantáneo.	Una llamada por artículo, no por usuario.	Igual.
Quitar datos personales de la pregunta	CODE	Expresiones regulares para correos, teléfonos y DPI; Jev falla con números.	Invisible.	Menos exposición a terceros.	Milisegundos.	Nulo.	Puede omitir datos escritos de forma inusual.
Clasificar la intención	JEV	Choice entre cinco intenciones; la confianza decide la ruta.	Ruta adecuada sin preguntar al usuario.	Pregunta y noticia salen a TypeSafe.	Menos de un segundo. Proveedor	Fracción de centavo.	Menor precisión en español; se mitiga con umbral.
Localizar el párrafo que responde	JEV	Choice sobre párrafos numerados y Noul ¿la noticia contiene la respuesta?	Cita verificable en lugar de texto libre.	Misma llamada.	Misma llamada.	Misma llamada.	No puede combinar datos de varios párrafos.
Detectar tema fuera de alcance o sensible	JEV	Noul para consejo médico, legal o financiero personal.	Mensaje claro en lugar de una respuesta riesgosa.	Misma llamada.	Misma llamada.	Misma llamada.	Literal; necesita criterios explícitos.
Decidir la ruta con umbrales	CODE	El código controla las acciones; Jev sólo informa.	Comportamiento predecible.	No sale nada.	Instantáneo.	Nulo.	Umbrales ajustables por versión de Jev.
Calcular hace cuánto pasó	CODE	Jev compara fechas mal; la aritmética va en código.	Dato correcto.	No sale nada.	Instantáneo.	Nulo.	Igual.
Explicar contexto o causas	LLM	Requiere redactar; Jev no genera texto.	Respuesta rica, etiquetada como generada.	Sólo pregunta y párrafos relevantes; store=false.	Segundos. Supuesto	Mayor costo; sólo en esta ruta.	Puede inventar; se muestra la fuente al lado.
Historial de la conversación	CODE	Guardarlo en nuestra MongoDB en vez de previous_response_id.	Igual.	El historial no queda en OpenAI.	Igual.	Almacenamiento propio.	Igual.

5. Flujo propuesto



6. Datos que salen y comparación Lean



Llamadas que aportan valor y llamadas evitables

Hoy hay una llamada al LLM por cada pregunta. Fecha, fuente y resumen no la necesitan. Las preguntas de dato puntual se resuelven con una cita. El LLM queda para explicar.

Costo por 1000 preguntas Supuesto

Supuesto	Actual	Propuesto
Llamadas a gpt-5-mini	1000	400
Tokens entrada / salida LLM	2000 / 400	1200 / 400
Llamadas a Jev, 1500 tokens	0	1000
Costo LLM	US$1.30	US$0.44
Costo Jev	0	US$0.06
Total	US$1.30	US$0.50

Se asume que 60 % de las preguntas son dato puntual, metadatos o fuera de tema. La salida del LLM incluye tokens de razonamiento.

Qué se gana y qué se pierde

Se gana latencia, costo y trazabilidad. Se pierde flexibilidad en preguntas ambiguas, se agrega un proveedor y aparece un caso nuevo de error: una mala ruta.

7. Medidas de Responsible AI

Datos mínimos

A Jev: pregunta sin datos personales y párrafos numerados. Al LLM: lo mismo, sólo en la ruta de explicación. Perfil, correo, temas e historial no salen. Se fija la versión jev-1.13.0 para que las respuestas no cambien sin aviso.

Límites e incertidumbre

- Etiqueta en cada respuesta: Extraído del párrafo N o Explicación generada por IA, puede contener errores.
- Confianza baja: No lo encontré con claridad en la noticia, con párrafos candidatos y opciones para seguir.
- No se muestran porcentajes crudos; se usan tres estados: seguro, revisar, no encontrado.

Si la decisión es incorrecta

La cita permite verificar en la noticia. El botón No responde mi pregunta pasa a la explicación del LLM o permite reformular. Cada reporte guarda ruta, confianza y versión, sin el texto, y se revisa cada semana para ajustar umbrales.

Riesgo de sesgo o exclusión

Jev rinde mejor en inglés. Quien escribe en español coloquial guatemalteco, con voseo, errores de ortografía o con el español como segunda lengua recibiría más rutas equivocadas y más respuestas de no encontrado.

Medida concreta

Antes de lanzar: 150 preguntas reales en español guatemalteco etiquetadas, con precisión medida por grupo. Si la precisión de un grupo queda bajo 85 %, su ruta por defecto es el LLM. En confianza baja se ofrecen sugerencias tocables en lugar de pedir que reescriba.

8. Conclusión

Arquitectura híbrida con el código al mando. Metadatos, resumen, filtros, fechas y rutas van en código. Jev toma las decisiones cerradas con una sola llamada por pregunta. El LLM sólo redacta cuando hay que explicar, con menos datos y sin guardar historial en el proveedor.

La persona recibe respuestas más rápidas, con cita y con un aviso cuando el sistema no está seguro.

9. Supuestos y lo que falta verificar

- Persona y necesidad: sin entrevistas; validar con 5 usuarios.
- Distribución de preguntas y tokens por turno: medir con registros reales.
- Latencia de Jev desde Guatemala y precisión en español: probar en el Playground.
- Qué registra la API por solicitud y plazo de conservación: preguntar a TypeSafe.
- Términos del Master Customer Agreement para uso por API.
- Disponibilidad: acceso temprano con lista de espera.
- Umbral de 85 % y tamaño de 150 preguntas: valores iniciales a revisar.

10. Fuentes consultadas

- Documentación Jev: https://docs.typesafe.ai/introduction
- Modelos, precio, límites, idiomas: https://docs.typesafe.ai/models
- Límites de jev-1.13: https://docs.typesafe.ai/model-jaggedness/jev-1.13
- Confianza: https://docs.typesafe.ai/confidence
- Preguntas en paralelo: https://docs.typesafe.ai/cookbooks/parallel_questions
- Legal y retención cero: https://docs.typesafe.ai/legal
- Política de privacidad: https://typesafe.ai/legal/privacy-policy
- Data Processing Agreement: https://typesafe.ai/legal/data-processing
- Términos de uso: https://typesafe.ai/legal/terms
- Afirmaciones de velocidad y costo: https://typesafe.ai
- Precio gpt-5-mini: https://developers.openai.com/api/docs/models/gpt-5-mini
- Código del Proyecto 2: backend/assistant y frontend de ai-assisted-news-app

Consultadas el 30 de septiembre de 2026.