Investigación sobre Jev para el rediseño del Proyecto 2

AI News (ai-assisted-news-app) · consulta sobre una noticia

Gustavo Cruz 22779 · Mathew Cordero 22982

30 de septiembre de 2026

Alcance

Documento de apoyo al board. Responde las tres preguntas de la parte 1 de la tarea para el flujo de consulta sobre una noticia. Cada dato lleva una de tres marcas:

- Verificado: leído en la documentación o en las políticas originales de TypeSafe u OpenAI.
- Proveedor: afirmación de TypeSafe sin método o datos que podamos revisar.
- Supuesto: estimación nuestra que falta medir.

Estado actual del Proyecto 2

Revisado en el repositorio ai-assisted-news-app, rama main.

- El frontend es una app Expo con login de Google o invitado y un feed con tres noticias de demostración (`frontend/src/services/newsService.ts`). No tiene pantalla de chat.
- El backend `backend/assistant` expone `POST /chat`. Recibe `message`, `user_id` y `previous_response_id`.
- Con `user_id`, lee de MongoDB la proyección `assistant_contexts`: nombre, locale, zona horaria, temas preferidos y artículos guardados. Ese contexto viaja a OpenAI en cada turno.
- El proveedor usa gpt-5-mini por la Responses API con `store=true`, razonamiento bajo y hasta 1600 tokens de salida.
- El prompt `prompts/system.md` sigue siendo el del asistente financiero NOVU.
- Toda pregunta, incluida una fecha o una fuente, pasa por el LLM. La respuesta es texto libre sin cita y sin señal de incertidumbre.

1. Qué puede resolver Jev y sus límites frente a un LLM

Jev es el primer modelo System One de TypeSafe. La versión vigente es jev-1.13.0. (Verificado)

Recibe un estado (texto, objeto JSON o arreglo de textos) y un conjunto de preguntas tipadas. Responde todas en paralelo en una sola llamada a `POST /v1/systemone`. (Verificado)

Primitiva	Qué responde	Salida
Choice	Cuál opción de una lista aplica	opción, probabilidad por opción, confianza
Score	Qué nivel de una rúbrica corresponde	nivel, probabilidad por nivel, confianza
Noul	Probabilidad de que una afirmación sea verdadera	valor entre 0 y 1

Tareas que encajan en nuestro flujo:

- Clasificar la intención de una pregunta (Choice).
- Elegir el párrafo de la noticia que responde (Choice sobre párrafos numerados).
- Verificar si la noticia contiene la respuesta (Noul).
- Detectar preguntas fuera de alcance o de consejo sensible (Noul).

Límites que TypeSafe documenta para jev-1.13 (Verificado):

- No genera texto, no conversa y no escribe código. Para redactar recomienda un modelo generativo.
- No cuenta de forma confiable ni hace aritmética.
- Compara mal fechas; recomienda extraer componentes y calcular en código.
- Lee las instrucciones de forma literal.
- Pierde precisión con estados grandes llenos de detalle irrelevante.
- El contenido adversarial dentro del estado puede mover la respuesta.
- No garantiza consistencia entre preguntas equivalentes formuladas distinto.
- Sólo acepta texto; 64k tokens por solicitud y 32k para el estado más la pregunta más larga.
- El idioma principal de entrenamiento es inglés. Otros idiomas funcionan con menor precisión y TypeSafe pide probar con contenido propio.

La confianza resume la forma de la distribución de probabilidades. TypeSafe sugiere tres rangos: actuar, confirmar o no actuar, con umbrales según el riesgo de cada acción. La calibración se mide sobre grupos de predicciones y no garantiza que una respuesta individual sea correcta. (Verificado)

Frente a un LLM, Jev cambia flexibilidad por respuestas acotadas. Un LLM redacta, combina información de varias partes y conversa. Jev sólo elige entre opciones definidas por nosotros, con probabilidad y confianza.

2. Datos que enviaríamos y políticas de TypeSafe

Datos que saldrían hacia TypeSafe en cada pregunta libre:

- Texto de la pregunta, después de quitar correos, teléfonos y números de DPI en código.
- Título y párrafos numerados de la noticia, que es contenido público.
- Las preguntas tipadas y sus opciones.

No saldrían `user_id`, nombre, correo, temas preferidos, artículos guardados ni historial.

Políticas revisadas:

- Entrenamiento: la política de privacidad dice que no entrenan ni ajustan modelos de IA con el input y que no lo divulgan a terceros salvo proveedores de servicio. La página de modelos repite que Jev no se entrena con solicitudes ni respuestas de clientes. (Verificado)
- Conservación: guardan datos personales mientras sea razonablemente necesario para dar el servicio o para fines comerciales. No hay plazo fijo. La retención cero está disponible sólo para clientes empresariales. (Verificado)
- Encargado de tratamiento: el DPA define al cliente como responsable y a TypeSafe como encargado. Se compromete a no vender datos y a procesarlos según instrucciones documentadas. Publica una lista de subencargados y avisa antes de agregar uno. (Verificado)
- Ubicación: el servicio está alojado en Estados Unidos. (Verificado)
- Telemetría: el sitio usa cookies, Google Analytics y registra IP, dispositivo, navegador y horarios de uso. No encontramos qué registra la API por cada solicitud ni si el SDK envía telemetría. (Supuesto, falta verificar)
- Términos de uso del sitio: piden no enviar información confidencial por el sitio y limitan la responsabilidad a US$100. El uso por API se rige por el Master Customer Agreement, que no revisamos a fondo. (Verificado / falta verificar)
- Acceso: Jev está en acceso temprano con lista de espera. Los límites de uso cambian sin aviso por la demanda. (Verificado)

3. Evidencia sobre velocidad, costo y recursos

Dato	Valor	Marca
Precio Jev	US$0.042 por millón de tokens de entrada; salida sin costo	Verificado
Precio gpt-5-mini	US$0.25 entrada, US$2.00 salida por millón	Verificado
Límites Jev	100k tokens/s y 40 solicitudes/s, ajustables sin aviso	Verificado
Velocidad frente a LLM	193.6x más rápido, 0.114 s frente a 8.566 s	Proveedor
Costo frente a LLM	444.6x más barato	Proveedor
Preguntas en lote	13 preguntas en una llamada: 0.27 s y US$0.0005; 13 llamadas: 2.71 s y US$0.0061	Proveedor
Cero alucinaciones	Cierto en el sentido de que sólo elige opciones dadas; puede elegir mal	Proveedor
Consumo de energía o hardware	No publicado	Falta verificar
Tokens por turno en AI News	2000 de entrada y 400 de salida con el LLM; 1500 de entrada con Jev	Supuesto
Proporción de preguntas resolubles sin LLM	60 %	Supuesto

Las cifras de velocidad del proveedor vienen de pruebas internas en tareas System One sin método publicado. No hay benchmarks independientes.

Estimación por 1000 preguntas (Supuesto):

	Actual	Propuesto
Llamadas a gpt-5-mini	1000	400
Costo LLM	US$1.30	US$0.44
Llamadas a Jev	0	1000
Costo Jev	US$0	US$0.06
Total	US$1.30	US$0.50

En recursos, Jev y gpt-5-mini corren en la infraestructura de cada proveedor. Para AI News el cambio es menos tokens procesados por LLM y lógica determinista en el contenedor FastAPI, con costo de cómputo despreciable. El consumo energético real no se puede comparar con la información publicada.

Pendiente de verificar

- Latencia real de Jev desde Guatemala y precisión con preguntas en español guatemalteco, con el Playground.
- Qué registra la API por solicitud y por cuánto tiempo.
- Cláusulas del Master Customer Agreement sobre datos enviados por API.
- Distribución real de preguntas y tokens por turno, con registros de uso.

Fuentes

Consultadas el 30 de septiembre de 2026.

- Introducción a Jev: https://docs.typesafe.ai/introduction
- System One: https://docs.typesafe.ai/concepts/system-one
- Estado: https://docs.typesafe.ai/concepts/state
- Modelos, precio, límites e idiomas: https://docs.typesafe.ai/models
- Límites de jev-1.13: https://docs.typesafe.ai/model-jaggedness/jev-1.13
- Confianza: https://docs.typesafe.ai/confidence
- Jev con agentes de código: https://docs.typesafe.ai/introduction/coding-agents
- Preguntas en paralelo: https://docs.typesafe.ai/cookbooks/parallel_questions
- Legal y retención cero: https://docs.typesafe.ai/legal
- Política de privacidad: https://typesafe.ai/legal/privacy-policy
- Data Processing Agreement: https://typesafe.ai/legal/data-processing
- Términos de uso: https://typesafe.ai/legal/terms
- Sitio de TypeSafe y afirmaciones de rendimiento: https://typesafe.ai
- Modelo gpt-5-mini y precio: https://developers.openai.com/api/docs/models/gpt-5-mini
- Código del Proyecto 2: `backend/assistant` y `frontend` en ai-assisted-news-app