Explicaciones locales con TreeSHAP en clasificación de dígitos manuscritos

Visualización y evaluación por eliminación

Nombre del estudiante
Universidad del Valle de Guatemala

4 de septiembre de 2026

Resumen

Este trabajo estudia explicaciones locales de un clasificador de imágenes mediante SHAP. Se entrenó un bosque aleatorio de 300 árboles con el conjunto público `digits`, compuesto por 1797 imágenes de dígitos manuscritos de 8×8 píxeles. El modelo alcanzó una exactitud de 96.94% y un F_1 macro de 0.969 en una partición de prueba estratificada. Se aplicó TreeSHAP a tres casos elegidos mediante reglas deterministas y se verificó la propiedad de aditividad con un error máximo de 2.50×10^{-8}. Para evaluar la fidelidad de las atribuciones, se sustituyeron los ocho píxeles con mayor aporte positivo y se comparó la caída de probabilidad con sustituciones aleatorias. Sobre los 349 aciertos, la caída mediana fue 0.633 para SHAP y 0.150 para el control aleatorio. Los resultados muestran cómo una explicación visual puede acompañarse de comprobaciones numéricas, sin interpretarla como evidencia causal.

Palabras clave: explicabilidad, SHAP, TreeSHAP, clasificación de imágenes, bosques aleatorios, reproducibilidad.

1 Introducción

Una métrica agregada indica cuántas predicciones acierta un sistema, pero no explica qué información sostuvo una decisión particular. Esta distinción importa incluso en un problema pequeño: dos imágenes pueden recibir la misma clase por patrones de píxeles diferentes, y un error de alta confianza puede revelar qué rasgos compiten en el modelo. SHAP (*SHapley Additive exPlanations*) formaliza atribuciones locales a partir de valores de Shapley y reúne varios métodos aditivos de explicación [6, 9]. Para ensambles de árboles, TreeSHAP permite calcular estas atribuciones eficientemente [7].

La pregunta de investigación es: *para tres casos representativos de dígitos manuscritos, qué píxeles aumentan o reducen la probabilidad de la clase predicha y, al sustituir los píxeles con mayor SHAP positivo, disminuye esa probabilidad más que al sustituir píxeles al azar?* La primera parte se responde con mapas locales; la segunda se contrasta mediante una prueba de eliminación. La hipótesis previa al análisis es que retirar píxeles con mayor aporte positivo producirá una caída mayor que el control aleatorio. El código, las selecciones, las figuras y los valores del texto se regeneran desde una sola ejecución.

2 Datos y clasificador

2.1 Conjunto de datos

Se utilizó `load_digits` de scikit-learn [8], una copia del conjunto de prueba de reconocimiento óptico de dígitos de UCI [2]. Contiene 1797 observaciones, diez clases y 64 atributos: la intensidad de cada píxel en el rango de 0 a 16. Al estar incluido en la biblioteca, el experimento no depende de enlaces de descarga ni de credenciales.

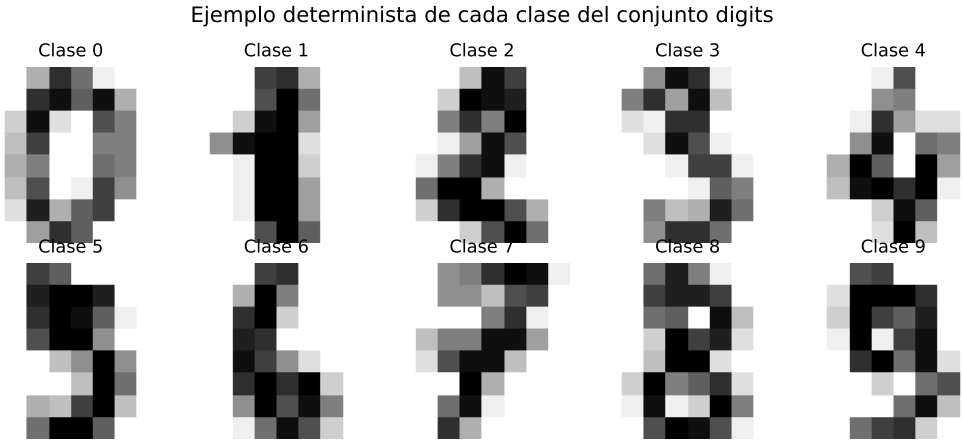


Figura 1: Una imagen seleccionada determinísticamente por cada clase. La resolución original es 8×8; la ampliación solo facilita la inspección visual.

Los índices se dividieron en 1437 observaciones de entrenamiento y 360 de prueba (80/20), con estratificación por clase y semilla 42. El script comprueba que no exista intersección entre ambas particiones.

2.2 Modelo y evaluación predictiva

Se ajustó un `RandomForestClassifier` [3] de 300 árboles, con selección de $\sqrt{64}$ atributos candidatos por división, semilla 42 y los demás hiperparámetros predeterminados de scikit-learn. El bosque recibe el vector aplanado de 64 intensidades. Se reportan exactitud, F_1 macro y matriz de confusión. Las probabilidades son la fracción media de votos por clase del ensamble y no se sometieron a calibración adicional.

3 Diseño de las explicaciones

3.1 TreeSHAP y referencia

Para una imagen x y una clase c, la explicación aditiva usada en este trabajo es

$$f_c(x) = \phi_{0,c} + \sum_{j=1}^{64} \phi_{j,c}, \tag{1}$$

donde $f_c(x)$ es la probabilidad producida por el bosque, $\phi_{0,c}$ es el valor esperado respecto a un conjunto de referencia y $\phi_{j,c}$ es la atribución del píxel j. Se empleó `TreeExplainer` con perturbación *interventional* y salida en probabilidad. La referencia contiene 100 imágenes de entrenamiento: diez seleccionadas sin reemplazo por cada clase con semilla 42. Por tanto, una atribución positiva significa que el píxel eleva la salida respecto a *esa referencia*; no significa que el píxel sea causal ni universalmente importante.

Los mapas usan una escala divergente centrada en cero: rojo indica apoyo a la clase mostrada y azul indica oposición. Se usa una escala común en los paneles para evitar que la normalización independiente exagere diferencias pequeñas.

3.2 Selección de tres imágenes

Para evitar escoger manualmente ejemplos favorables, se fijaron tres reglas antes de observar los mapas:

1. el acierto cuya confianza está más cerca de la mediana de todos los aciertos;
2. el acierto con el menor margen entre las dos clases más probables, excluyendo el caso anterior;
3. el error de mayor confianza; si no hubiera errores, un segundo acierto de bajo margen.

Para un acierto se contrasta la clase predicha con la segunda opción; para un error se contrasta con la clase verdadera.

3.3 Prueba de eliminación

Una visualización coherente no garantiza fidelidad [1]. Por ello se ordenaron los píxeles según su SHAP para la clase predicha y se sustituyeron los primeros $k \in \{1, 2, 4, 8\}$ por la media del mismo píxel en la referencia. Para cada k, el control repite 200 selecciones uniformes de k píxeles. Además, se calculó *drop@8* en todos los aciertos de prueba y se comparó cada caída SHAP con la media de 100 máscaras aleatorias para esa misma imagen. Un bootstrap emparejado de 2,000 remuestreos resume la incertidumbre de la mediana de las diferencias. Esta intervención se inspira en evaluaciones de eliminación, pero no reentrena el modelo [4]; solo prueba sensibilidad en entradas modificadas.

4 Resultados

4.1 Desempeño del clasificador

El modelo clasificó correctamente 349 de 360 imágenes y cometió 11 errores: exactitud 96.94% y F_1 macro 0.969. La Figura 2 permite localizar los pares de clases en los que ocurrieron las confusiones, en lugar de reducir el desempeño a una sola cifra.

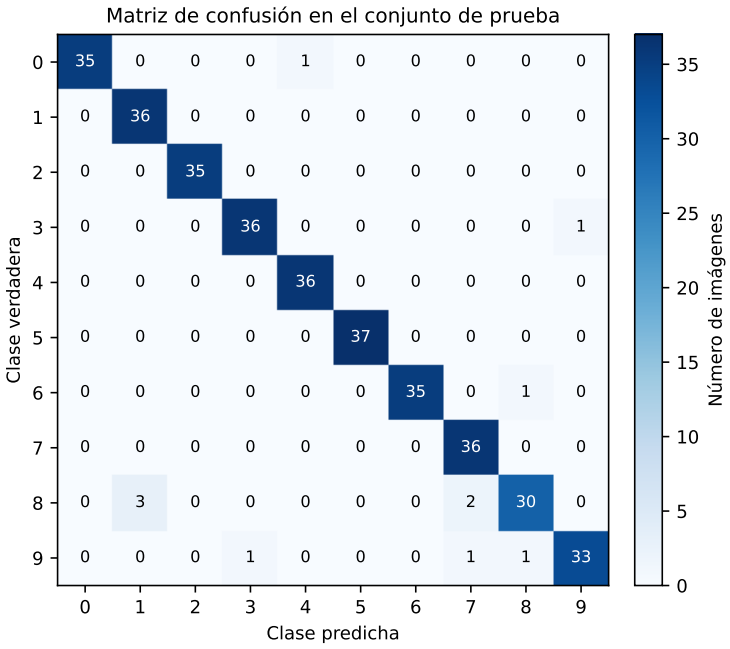


Figura 2: Matriz de confusión de la partición de prueba. Los valores son conteos.

4.2 Casos locales

La Tabla 1 registra la selección exacta. El margen es la diferencia entre las dos probabilidades más altas. Conservar el índice del conjunto completo permite recuperar cada imagen sin archivos externos.

Cuadro 1: Tres casos seleccionados por reglas deterministas.

Caso	Criterio	Índice	y	$\hat{y}$	$p(\hat{y})$	Margen	Acierto
1	Acierto de confianza mediana	1089	3	3	0.817	0.727	Sí
2	Acierto correcto de menor margen	1593	2	2	0.330	0.007	Sí
3	Error de mayor confianza	1553	8	1	0.570	0.410	No

En la Figura 3, la primera columna muestra la entrada, la segunda explica la clase predicha y la tercera presenta una explicación contrastiva. Los mapas no deben leerse como segmentaciones del trazo: cada celda expresa cuánto cambia la salida del bosque en la descomposición de la Ecuación 1. La reconstrucción de las 30 salidas (tres imágenes por diez clases) tuvo un error absoluto máximo de 2.50×10^{-8}, por debajo de la tolerancia predefinida de 10^{-5}.

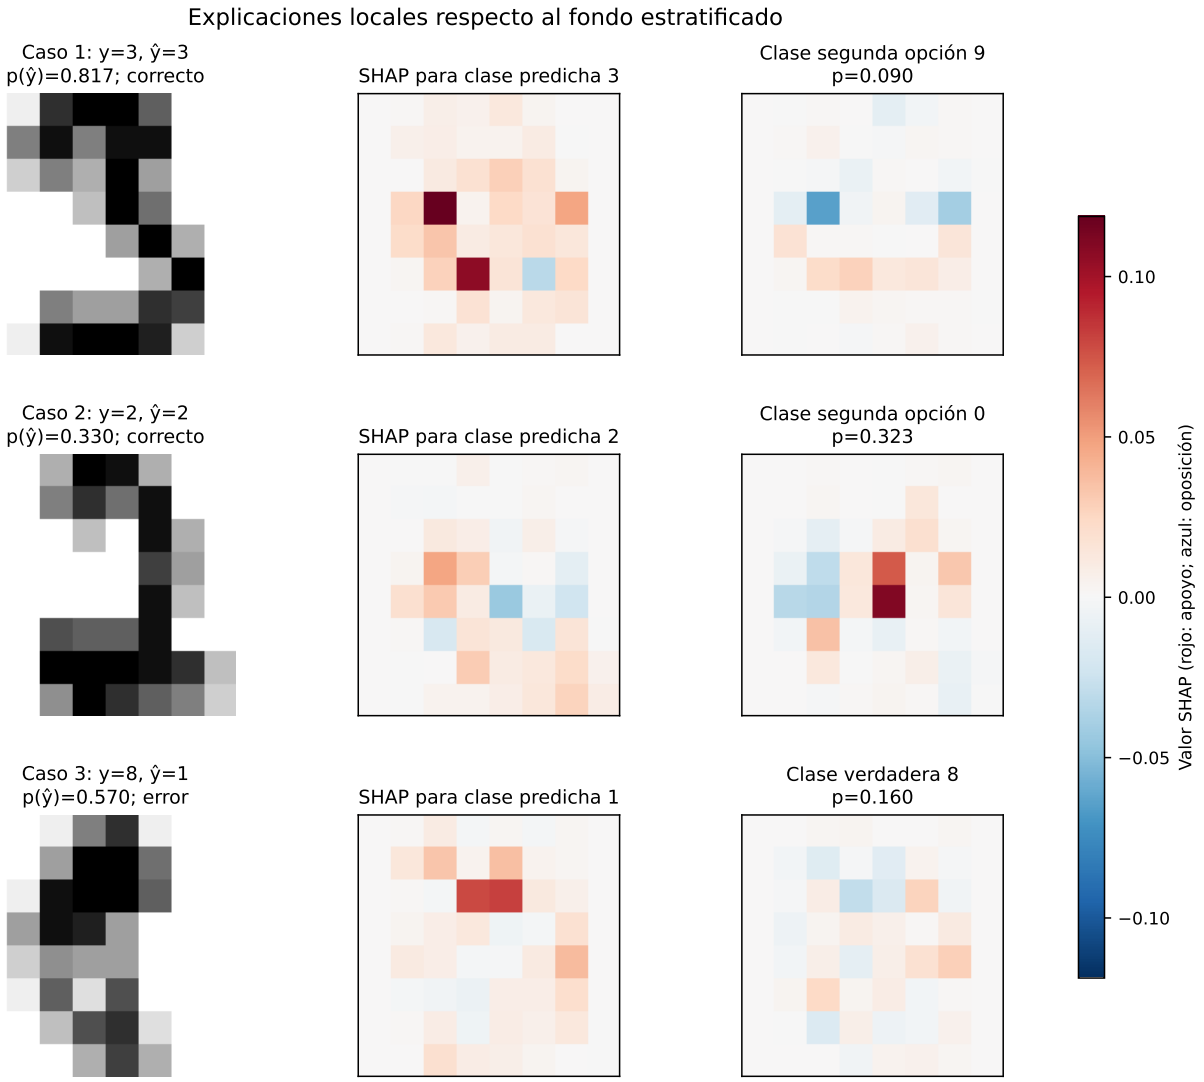


Figura 3: Imágenes y mapas TreeSHAP. Rojo: aporte positivo; azul: aporte negativo, siempre respecto a la referencia estratificada. Para los aciertos se muestra como contraste la segunda clase más probable; para el error, la clase verdadera.

4.3 Fidelidad por eliminación

La Tabla 2 presenta el resultado al sustituir ocho píxeles en cada caso. Una caída positiva indica que la intervención redujo la probabilidad original. Las curvas completas de la Figura 4 conservan también todos los valores de k y el intervalo percentil del control aleatorio.

Cuadro 2: Eliminación de ocho píxeles en los casos seleccionados.

Caso	p_0	p_{SHAP}	Caída SHAP	$\bar{p}_{\text{azar}}$	Caída azar
1	0.817	0.123	0.693	0.685	0.131
2	0.330	0.100	0.230	0.304	0.026
3	0.570	0.073	0.497	0.422	0.148

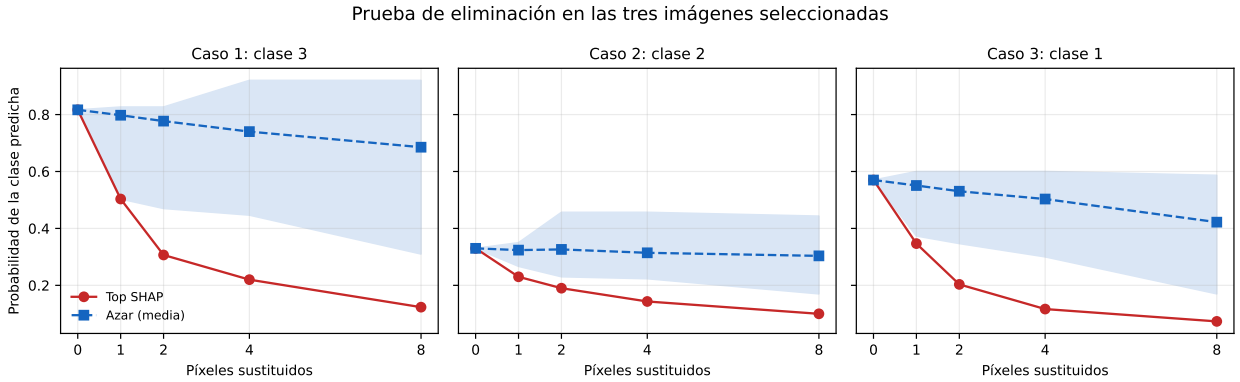


Figura 4: Probabilidad de la clase originalmente predicha al sustituir píxeles. La banda azul es el intervalo percentil 2.5–97.5% de 200 máscaras aleatorias.

En el análisis global, la caída mediana fue 0.633 al sustituir los ocho píxeles de mayor SHAP y 0.150 para la media aleatoria. La diferencia emparejada mediana fue 0.477, con intervalo bootstrap descriptivo del 95% [0.458, 0.491]. La caída SHAP superó la caída aleatoria media en 100.0% de los aciertos. Estos números evalúan la hipótesis de sensibilidad planteada, no la corrección semántica ni la causalidad de cada mapa.

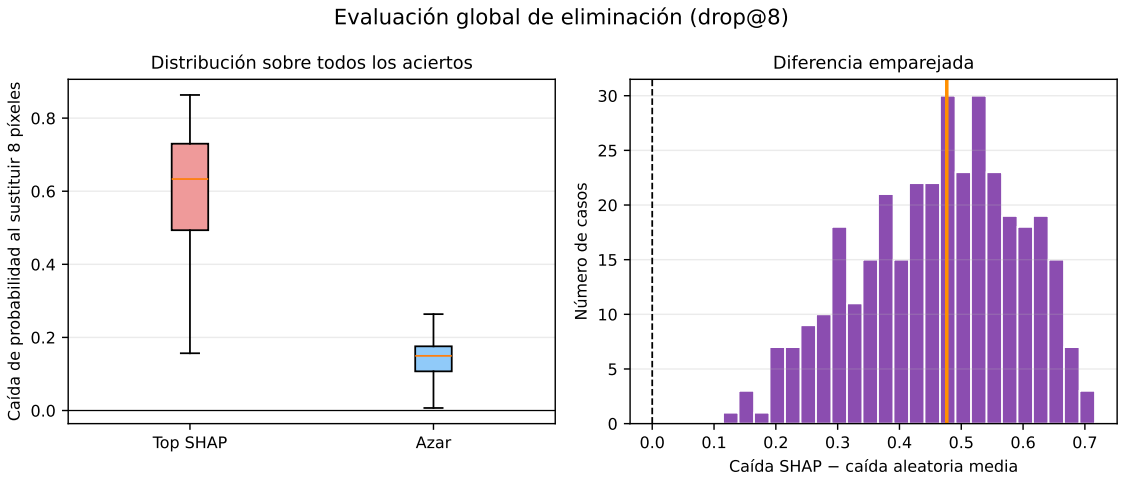


Figura 5: Drop@8 sobre los 349 aciertos. Izquierda: distribuciones de caída; derecha: diferencias emparejadas entre SHAP y el control aleatorio.

5 Discusión y limitaciones

El experimento relaciona tres niveles de evidencia: desempeño agregado, explicaciones locales y una prueba de sensibilidad. La aditividad confirma que los valores reconstruyen la salida explicada, mientras que la eliminación pregunta si los píxeles con atribución alta afectan más la predicción que una selección sin información. Ninguna de las dos comprobaciones demuestra que el modelo razone como una persona.

Las conclusiones están limitadas por los siguientes factores:

- **Escala y dominio.** `digits` es pequeño, monocromático y de baja resolución; no representa el comportamiento de clasificadores sobre imágenes reales.
- **Arquitectura.** El bosque recibe 64 atributos planos y no modela explícitamente vecindad, traslación ni estructura espacial.
- **Referencia y dependencia.** Los valores SHAP cambian con la población de fondo y con el supuesto de perturbación. Los píxeles vecinos están correlacionados, de modo que repartir crédito entre ellos no tiene una única interpretación causal [5].
- **Entradas intervenidas.** Sustituir intensidades por medias puede crear imágenes fuera de la distribución. La prueba mide sensibilidad del modelo fijo y no incluye el reentrenamiento recomendado por protocolos como ROAR.
- **Alcance local.** Tres imágenes facilitan una auditoría concreta, pero no resumen toda la población. El análisis drop@8 amplía la comprobación únicamente a los aciertos de esta partición.
- **Probabilidad.** Los votos del bosque no fueron calibrados; la confianza se interpreta como salida del modelo, no como frecuencia garantizada de acierto.

6 Reproducibilidad

El paquete incluye el código canónico, un notebook de ejecución, resultados tabulares, figuras en PNG/PDF, el modelo serializado, bibliografía, registro de prompts y una lista ampliada de limitaciones. La ejecución verificada utilizó Python 3.11.9, scikit-learn 1.7.2 y SHAP 0.51.0. Desde la raíz, el flujo completo en PowerShell es:

```
powershell -ExecutionPolicy Bypass -File .\reproduce.ps1
```

El script crea un entorno Python 3.11 local, instala versiones fijadas, ejecuta el experimento, compila este documento y valida archivos, métricas, forma de las atribuciones, aditividad y referencias LaTeX. Los valores numéricos se insertan desde `results/generated_values.tex`; las tablas también se generan automáticamente.

7 Conclusiones

TreeSHAP permitió descomponer, por clase y por píxel, tres predicciones de un bosque aleatorio entrenado sobre dígitos manuscritos. Las reglas de selección explícitas, la comprobación de adi-

tividad y el control aleatorio de eliminación reducen decisiones analíticas ocultas y hacen que las afirmaciones sean auditables. El ejercicio también muestra el límite central de una explicación local: atribuir la salida de un modelo no equivale a descubrir causas ni a validar el razonamiento humano. Para trabajos futuros, convendría repetir el protocolo con imágenes de mayor resolución, modelos convolucionales, varias referencias SHAP y pruebas que mantengan las intervenciones dentro de la distribución de datos.

Declaración de asistencia y trazabilidad

Se utilizó un asistente de IA para proponer la estructura, generar una primera versión del código y del texto, y apoyar la verificación técnica. Las decisiones, comandos y limitaciones están documentados en `prompts/prompt_log.md` y `LIMITATIONS.md`. Antes de entregar, la persona autora debe revisar las afirmaciones, ejecutar el paquete y reemplazar el campo de autoría; la responsabilidad final sobre el contenido no se delega al asistente.

Referencias

[1] Julius Adebayo, Justin Gilmer, Michael Muelly, Ian Goodfellow, Moritz Hardt, and Been Kim. Sanity checks for saliency maps. In *Advances in Neural Information Processing Systems 31*, 2018. URL https://proceedings.neurips.cc/paper/2018/hash/294a8ed24b1ad22ec2e7efea049b8737-Abstract.html.

[2] Ethem Alpaydin and C. Kaynak. Optical recognition of handwritten digits. UCI Machine Learning Repository, 1998.

[3] Leo Breiman. Random forests. *Machine Learning*, 45(1):5–32, 2001. doi: 10.1023/A:1010933404324.

[4] Sara Hooker, Dumitru Erhan, Pieter-Jan Kindermans, and Been Kim. A benchmark for interpretability methods in deep neural networks. In *Advances in Neural Information Processing Systems 32*, 2019. URL https://proceedings.neurips.cc/paper/2019/hash/fe4b8556000d0f0cae99daa5c5c5a410-Abstract.html.

[5] Dominik Janzing, Lenon Minorics, and Patrick Blöbaum. Feature relevance quantification in explainable ai: A causal problem. In *Proceedings of the 23rd International Conference on Artificial Intelligence and Statistics*, volume 108 of *Proceedings of Machine Learning Research*, pages 2907–2916, 2020. URL https://proceedings.mlr.press/v108/janzing20a.html.

[6] Scott M. Lundberg and Su-In Lee. A unified approach to interpreting model predictions. In *Advances in Neural Information Processing Systems 30*, pages 4765–4774, 2017. URL https://proceedings.neurips.cc/paper/2017/hash/8a20a8621978632d76c43dfd28b67767-Abstract.html.

[7] Scott M. Lundberg, Gabriel Erion, Hugh Chen, Alex DeGrave, Jordan M. Prutkin, Bala Nair, Ronit Katz, Jonathan Himmelfarb, Nisha Bansal, and Su-In Lee. From local explanations to global understanding with explainable ai for trees. *Nature Machine Intelligence*, 2:56–67, 2020. doi: 10.1038/s42256-019-0138-9.

[8] Fabian Pedregosa, Gaël Varoquaux, Alexandre Gramfort, Vincent Michel, Bertrand Thirion, Olivier Grisel, Mathieu Blondel, Peter Prettenhofer, Ron Weiss, Vincent Dubourg, et al. Scikit-learn: Machine learning in python. *Journal of Machine Learning Research*, 12:2825–2830, 2011. URL https://jmlr.org/papers/v12/pedregosa11a.html.

[9] Lloyd S. Shapley. A value for n-person games. In Harold W. Kuhn and Albert W. Tucker, editors, *Contributions to the Theory of Games II*, pages 307–317. Princeton University Press, 1953. doi: 10.1515/9781400881970-018.